

データ定義書 | 受講データ（学習用の想定データ）

このデータは、Craft College（オンライン学習サービス）を題材にした、学習用の想定データです。演習のために作った架空のデータで、実在の受講実績ではありません。この定義書に出てくる人数・点数・学習ログも、すべて演習用に作った値です。

データは4つのファイルからなり、**受講生ID** と **課題ID** でつながっています。金額や個人を特定する情報は含みません。

このデータは 2-1、2-2、2-3 の3単元で共通です。ただし同じものを何度も配らないよう、2-1 の `dataset` フォルダにだけ置いています。2-2「データ分析Webアプリ入門」・2-3「データ分析Webアプリ応用」に進むときは、この `dataset` フォルダをその単元のフォルダにコピーして使ってください。

データは **dataset/データ一式.zip** にまとめてあります。ノートブックの準備セルが自動で解凍するので、自分で解凍する必要はありません。解凍後は **dataset/** に普通のCSVが並ぶので、Excelなどで中身を直接見ることもできます。

ファイルの関係（結合キー）

- **受講生.csv** … 受講生1人が1行。すべての起点。
- **課題マスタ.csv** … どの講座にどんな課題があるか。**課題ID** で「課題成績」とつながる。
- **課題成績.csv** … 誰が・どの課題で何点取ったか。**受講生ID** で「受講生」、**課題ID** で「課題マスタ」とつながる。
- **学習ログ.csv** … 受講生の学習クリック履歴。**受講生ID** で「受講生」とつながる（データサイエンス基礎の受講生350人分のみ）。1人が何十回もクリックするため行数が多く、受講生ごとの集計が必要です。

つなぎ方をまとめると、次のようになります。

つなぐ元	キー	つなぐ先
受講生.csv	受講生ID	課題成績.csv
課題成績.csv	課題ID	課題マスタ.csv
受講生.csv	受講生ID	学習ログ.csv

1. 受講生.csv（3,000行）

列名	型	意味	取りうる値の例
受講生ID	整数	受講生を一意に識別する番号	617521 など

列名	型	意味	取りうる値の例
講座名	文字列	受講している講座	経営データ入門、機械学習概論、AI活用実践、データサイエンス基礎、マーケティング分析、統計学入門、Pythonプログラミング（全7講座）
開講期	文字列	いつ開講された回か	2024年秋
性別	文字列	性別	男、女
年代	文字列	年齢の区分	20～34歳、35～54歳、55歳以上
地域	文字列	居住地域	関東、東北、中部、近畿、中国、四国、九州・沖縄、北海道
学歴	文字列	最終学歴	大学院卒、大卒、高卒、専門・その他、その他
過去受講回数	整数	これまでに受講した回数	0、1、2 …
受講単位数	整数	受講している単位の量	30、60、90 …
最終結果	文字列	講座の最終的な結果	優秀合格、合格、不合格、途中退会

2. 課題マスタ.csv（57行）

列名	型	意味	取りうる値の例
課題ID	整数	課題を一意に識別する番号	34873 など
講座名	文字列	その課題が属する講座	（上の7講座）
課題種別	文字列	課題の種類	レポート課題、小テスト、修了試験
実施日（開講何日目）	整数	開講から何日目に実施されるか	19、54 …（まれに空欄あり）
成績への重み	小数	最終成績に占めるその課題の重み	10.0 など

3. 課題成績.csv（14,376行）

列名	型	意味	取りうる値の例
受講生ID	整数	どの受講生か（受講生.csv とつながる）	617521
課題ID	整数	どの課題か（課題マスタ.csv とつながる）	34873
提出日（開講何日目）	整数	開講から何日目に提出したか	18、52 …
点数	小数	その課題の点数（0～100）。まれに欠損あり	78、0、（空欄）

4. 学習ログ.csv (約71,000行)

データサイエンス基礎の受講生350人分のみ。1人が何十回もクリックするため行数が多く、そのままでは1人1行の分析に使えない（受講生ごとの集計が必要）。

列名	型	意味	取りうる値の例
受講生ID	整数	どの受講生か（受講生.csv とつながる）	582530
経過日数	整数	開講日を0とした経過日数（マイナスは開講前）	-18、5、120 …
行動種別	文字列	どの種類のページを見たか	教材ページ、トップページ、配布資料、小テスト
クリック数	整数	その日のその行動のクリック回数	5、12 …

補足

「合格」の扱いは分析者が決めます（例：優秀合格+合格 を合格とみなす）。この定義は分析を通して一貫させてください。点数の欠損は、未採点または未提出を表します。平均を出すときと、提出の有無を数えるときで、扱いを変える必要があります。